

Práctica de Laboratorio: Preprocesamiento y Limpieza de Datos para Machine Learning

Asignatura: Minería de Datos / Machine Learning

Modalidad: Aprendizaje en contacto con el Docente

Herramienta: Jupyter Notebook / JupyterLab

Dataset: `dataset_limpieza_datos.csv`

1. Objetivo de la Práctica

Desarrollar habilidades prácticas en la preparación de datos crudos (*raw data*) para su posterior uso en modelos de entrenamiento de Machine Learning. Al finalizar, el estudiante deberá ser capaz de identificar anomalías y tratar el mismo conjunto de datos utilizando dos metodologías distintas de la industria.

2. Descripción del Problema

Se les ha proporcionado el archivo `dataset_limpieza_datos.csv`, el cual contiene 10,000 registros con información demográfica y socioeconómica. Este dataset presenta múltiples problemas de calidad de datos, incluyendo:

- Valores nulos (NaN).
- Errores tipográficos y de formato en cadenas de texto (espacios extra, mayúsculas/minúsculas).
- Valores ilógicos (edades negativas, número de hijos en decimales).
- Valores atípicos extremos (*outliers*).

Su tarea es aplicar técnicas de limpieza y transformación para dejar el dataset en un estado óptimo para el modelado.

3. Instrucciones de Desarrollo

Deberán crear un único Jupyter Notebook (`.ipynb`) estructurado con celdas de código y celdas de texto (Markdown) explicando sus decisiones. La práctica se divide en tres fases obligatorias:

Fase 1: Exploración Inicial (EDA Básico)

1. Importen las librerías necesarias (`pandas`, `numpy`).
2. Carguen el dataset.
3. Utilicen funciones descriptivas (`.info()`, `.describe()`, `.isnull().sum()`) para redactar un breve reporte en Markdown de 3 a 5 viñetas sobre el estado inicial de los datos y las anomalías detectadas.

Fase 2: Enfoque 1 - Tratamiento Manual e Iterativo (Pandas)

En esta sección, aplicarán las transformaciones paso a paso modificando directamente un DataFrame. Este enfoque es excelente para el análisis ad-hoc y la comprensión profunda de los datos.

- **Reemplazo y Casteo:** Identifiquen valores negativos en `edad`, `hijos` e `ingresos` y conviértanlos a nulos (`NaN`). Asegúrense de que la columna de `hijos` y `edad` queden como números enteros (`int`).
- **Mapeo y Strings:** Unifiquen las categorías de las columnas `genero`, `ciudad` y `nivel_educacion`. Utilicen `.str.strip()`, `.str.lower()` o diccionarios con la función `.replace()` o `.map()`.
- **Imputación Manual:** Rellenen los valores nulos de las variables numéricas usando la mediana de la columna respectiva (`.fillna(df['col'].median())`) y las categóricas con la moda.
- **Estandarización Manual:** Creen una función manual (o usen operaciones matemáticas vectorizadas de Pandas) para aplicar la fórmula de estandarización $Z = (x - \mu)/\sigma$ a la columna de ingresos.

Fase 3: Enfoque 2 - Automatización con Pipelines (Scikit-Learn)

Vuelvan a cargar el dataset original (crudo) en un nuevo DataFrame para no mezclarlo con la Fase 2. En esta sección, simularán un entorno de producción donde los datos nuevos deben pasar por un flujo automatizado.

- **Separación de Variables:** Definan listas separadas para sus columnas numéricas y categóricas.
- **Pipeline Numérico:** Creen un `Pipeline` de *Scikit-Learn* que realice dos pasos secuenciales:
 1. `SimpleImputer` (estrategia: mediana).
 2. `StandardScaler` (para estandarizar las escalas).
- **Pipeline Categórico:** Creen otro `Pipeline` para las variables de texto que realice:
 1. `SimpleImputer` (estrategia: valor más frecuente).
 2. *Opcional (Puntos extra):* Agregar un `OneHotEncoder` para transformar las categorías en variables dummy.
- **ColumnTransformer:** Unan ambos pipelines utilizando un `ColumnTransformer`.
- **Ejecución:** Apliquen el método `.fit_transform()` al dataset crudo y muestren el resultado final en un DataFrame procesado.

4. Entregables y Rúbrica de Evaluación

Deben subir a la plataforma el **archivo .ipynb** ejecutado (con los *outputs* visibles en las celdas).

Criterio	Descripción	Ponderación
Análisis Inicial	Correcta identificación de anomalías y nulos. Uso de Markdown para documentar hallazgos.	15%
Enfoque Pandas	Correcta limpieza de texto, imputación lógica y casteo de tipos sin perder información valiosa.	35%
Enfoque Pipeline	Construcción correcta del <code>ColumnTransformer</code> e integración fluida de transformadores numéricos y categóricos.	35%
Documentación	Código limpio, comentado y celdas de Markdown justificando el <i>por qué</i> de las decisiones (ej. por qué usar mediana y no media).	15%

Pregunta de reflexión final (Responder en Markdown al final del Notebook):

¿Cuál de los dos enfoques presentados considera más adecuado si el día de mañana la empresa recibe 50,000 registros nuevos cada hora para predecir en tiempo real? Justifique su respuesta.